

# Machine Learning

## MDS-211 Magister en Data Science

Sergio Hernández  
shernandez@ucm.cl



Universidad Católica del Maule

Motivación

¿Qué es el Aprendizaje Estadístico?

Estimación de  $f$

Compensación Sesgo–Varianza

Aprendizaje Supervisado vs. No Supervisado

Problemas de Regresión vs. Clasificación

Evaluación de Modelos

Sobreajuste

# ML Hype

● machine learning  
Search term

+ Compare

Worldwide ▼

2004 - present ▼

All categories ▼

Web Search ▼

Interest over time ?



# ¿Qué es el Aprendizaje Estadístico?


Supongamos que observamos una **respuesta**  $Y$  y  $p$  **predictores**  $X_1, X_2, \dots, X_p$ .

Se asume que existe una relación:

$$Y = f(X) + \varepsilon$$

- ▶  $f$  es una función **desconocida** de  $X = (X_1, \dots, X_p)$
- ▶  $\varepsilon$  es el **error aleatorio irreducible**, independiente de  $X$  con  $\mathbb{E}[\varepsilon] = 0$

**El Aprendizaje Estadístico** es el conjunto de métodos para **estimar**  $f$ .



The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Trevor Hastie, Robert Tibshirani, Jerome H. Friedman. Springer Science & Business Media, 2001

# ¿Por qué Estimar $f$ ?

## Predicción

Con una estimación  $\hat{f}$ , podemos predecir  $Y$  para nuevas observaciones  $X$ :

$$\hat{Y} = \hat{f}(X)$$

El error cuadrático esperado descomponible es:

$$\mathbb{E}[Y - \hat{Y}]^2 = \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{Irreducible}}$$

⇒ Podemos minimizar solo el error **reducible**.

## Inferencia

Comprender **cómo**  $Y$  se relaciona con  $X_1, \dots, X_p$ :

- ▶ ¿Qué predictores están **asociados** con la respuesta?
- ▶ ¿Cuál es la **dirección** de la relación?
- ▶ ¿La relación es **lineal** o más compleja?

**Nota:** Predicción e Inferencia requieren diferentes métodos (interpretabilidad vs. precisión).

# ¿Cómo Estimamos $f$ ?

## Datos de entrenamiento:

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

Dos enfoques principales:

## 1. Métodos Paramétricos


1. Asumir una **forma funcional** para  $f$   
Ej:  $f(X) = \beta_0 + \beta_1 X$
2. **Estimar los parámetros** a partir de datos  
Ej: mínimos cuadrados

✓ **Simple**    ✗ Pueden alejarse de la  $f$  real

## 2. Métodos No Paramétricos

No asumen forma para  $f$ ; buscan una estimación **suave** que se ajuste a los datos.

✓ **Flexibles**    ✗ Necesitan más datos ( $n$  grande)




# Compensación Sesgo–Varianza

El error de prueba esperado para un punto  $x_0$  se descompone:

$$\mathbb{E}[y_0 - \hat{f}(x_0)]^2 = \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} + \underbrace{[\text{Sesgo}(\hat{f}(x_0))]^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\varepsilon)}_{\text{Irreducible}}$$


- **Varianza:** cuánto cambia  $\hat{f}$  si usamos otro conjunto de entrenamiento
- **Sesgo:** error introducido al aproximar un problema real complejo con un modelo simple

⇒ Más flexibilidad ⇒ menos sesgo, más varianza




# Sesgo-Varianza: Ilustración

Modelo lineal (alto sesgo)



↑ Sesgo   ↓ Varianza

Grado 4 (equilibrado)



Compromiso Óptimo


↓ Sesgo   ↑ Varianza



## Aprendizaje Supervisado

Para cada observación  $x_i$ , existe una respuesta  $y_i$  asociada.


- ▶ Regresión lineal, logística
- ▶ GAM, árboles, SVM, redes neuronales ...



## Aprendizaje No Supervisado

Solo se observan  $x_i$ ; **no hay** respuesta  $y_i$ .  
Buscamos **estructura oculta**.


- ▶ Análisis de clúster, PCA, mezclas gaussianas



## Regresión

La respuesta  $Y$  es **cuantitativa** (numérica continua).


- ▶ Precio de una acción
- ▶ Temperatura máxima
- ▶ Ingreso anual



## Clasificación

La respuesta  $Y$  es **cualitativa** (categórica).

- ▶ Correo: ¿spam o no?
- ▶ Tumor: ¿maligno o benigno?
- ▶ Dígito manuscrito: 0–9



## Métrica más común — Regresión:


$$\text{MSE}_{\text{entren.}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$$

### ¡El MSE de entrenamiento no es suficiente!

No nos interesa qué tan bien funciona el modelo en los datos que usamos para ajustarlo, sino en **datos nuevos** (datos de prueba).

### Queremos minimizar:

$$\text{MSE}_{\text{prueba}} = \mathbb{E}[(y_0 - \hat{f}(x_0))^2]$$



## Definition

Un modelo **sobreajustado** aprende el **ruido** de los datos de entrenamiento, en lugar de la **señal** verdadera.


### Síntomas del sobreajuste:

- ▶  $MSE_{entrenamiento} \approx 0$
- ▶  $MSE_{prueba} \gg MSE_{entrenamiento}$
- ▶ El modelo es muy complejo

### Soluciones:

- ▶ Validación cruzada
- ▶ Regularización (Ridge, Lasso)
- ▶ Reducir la complejidad del modelo

Sobreajuste al ruido



# La Maldición de la Dimensionalidad

Al aumentar  $p$  (número de predictores):

- ▶ El volumen del espacio crece **exponencialmente**
- ▶ Los datos se vuelven **muy escasos**
- ▶ Los métodos locales (KNN) fallan

## Ejemplo

Para capturar el 10% de los datos en  $p$  dimensiones, necesitamos un vecindario que abarque:

$$\ell = 0.1^{1/p}$$

fracción del rango en cada dimensión.

| $p$ | $\ell$ |
|-----|--------|
| 1   | 10%    |
| 2   | 31.6%  |
| 10  | 79.4%  |

