

Machine Learning

MDS-211 Magister en Data Science

Sergio Hernández
shernandez@ucm.cl



Universidad Católica del Maule



Qué es Feature Engineering?

Definición

Es el proceso de crear nuevos descriptores a partir de los datos en bruto, de manera de aumentar el poder predictivo de los algoritmos de minería de datos.

Definición

Es el proceso de crear nuevos descriptores a partir de los datos en bruto, de manera de aumentar el poder predictivo de los algoritmos de minería de datos.

- ▶ Datos numéricos : representan mediciones cuantitativas, por ejemplo cantidad de casos (valores discretos) o registro de temperaturas (valores continuos).

Definición

Es el proceso de crear nuevos descriptores a partir de los datos en bruto, de manera de aumentar el poder predictivo de los algoritmos de minería de datos.

- ▶ Datos numéricos : representan mediciones cuantitativas, por ejemplo cantidad de casos (valores discretos) o registro de temperaturas (valores continuos).
- ▶ Datos categóricos : representan valores cualitativos, por ejemplo sexo, estado civil, etc.

Definición

Es el proceso de crear nuevos descriptores a partir de los datos en bruto, de manera de aumentar el poder predictivo de los algoritmos de minería de datos.

- ▶ Datos numéricos : representan mediciones cuantitativas, por ejemplo cantidad de casos (valores discretos) o registro de temperaturas (valores continuos).
- ▶ Datos categóricos : representan valores cualitativos, por ejemplo sexo, estado civil, etc.
- ▶ Datos ordinales : contiene datos categóricos y numéricos, por ejemplo valores de cuestionarios (respuesta 1,2,3,..).



Transformación Logarítmica

- ▶ Es una transformación monótona ya que cambia la escala pero no la posición relativa del dato.

Transformación Logarítmica

- ▶ Es una transformación monótona ya que cambia la escala pero no la posición relativa del dato.
- ▶ La función logaritmo comprime el rango de valores altos y expande el rango de valores bajos, por lo tanto permite reducir el sesgo de los datos en bruto.

$$x = \log_{10}(x) \quad (1)$$



- ▶ Los modelos basados en expansiones lineales de las entradas son altamente susceptibles al rango de las variables. Algunas transformaciones comunmente usadas son:
 - ▶ **Escalamiento Min-Max** : Comprime los valores originales al intervalo $[0, 1]$.

$$x = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (2)$$

- ▶ **Estandarización** : Re-escala los valores originales de modo que tengan media 0 y varianza 1.

$$x = \frac{x - \text{mean}(x)}{\sqrt{\text{var}(x)}} \quad (3)$$

- ▶ Los descriptores de interacción calculan el producto de dos descriptores.

- ▶ Los descriptores de interacción calculan el producto de dos descriptores.
- ▶ Por ejemplo si consideramos el siguiente modelo lineal:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 \quad (4)$$

- ▶ Los descriptores de interacción calculan el producto de dos descriptores.
- ▶ Por ejemplo si consideramos el siguiente modelo lineal:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 \quad (4)$$

- ▶ Es posible crear nuevos descriptores de interacción, combinando las variables de entrada:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_{1,2}x_1x_2 + w_{1,3}x_1x_3 + w_{2,3}x_2x_3 \quad (5)$$

- ▶ Los descriptores polinomiales calculan polinomios de orden p .

- ▶ Los descriptores polinomiales calculan polinomios de orden p .
- ▶ Por ejemplo si consideramos el siguiente modelo lineal:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 \quad (6)$$

- ▶ Los descriptores polinomiales calculan polinomios de orden p .
- ▶ Por ejemplo si consideramos el siguiente modelo lineal:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 \quad (6)$$

- ▶ Es posible crear nuevos descriptores de interacción, combinando las variables de entrada:

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + w_{1,1}x_1^2 + w_{2,2}x_2^2 + w_{3,3}x_3^2 \quad (7)$$

One Hot Encoding

- ▶ One Hot Encoding es una transformación para variables categoricas que utiliza 1 bit para cada categoría.

One Hot Encoding

- ▶ One Hot Encoding es una transformación para variables categoricas que utiliza 1 bit para cada categoría.
- ▶ Si la variable original contiene k categorías, entonces OHE crea k columnas.

One Hot Encoding

- ▶ One Hot Encoding es una transformación para variables categóricas que utiliza 1 bit para cada categoría.
- ▶ Si la variable original contiene k categorías, entonces OHE crea k columnas.
- ▶ Las k columnas son dependientes, por lo tanto generalmente se usan las $k - 1$ primeras columnas para crear modelos lineales.

Id	Ciudad	Renta
1	Santiago	2.5
2	Rancagua	1.3
3	Talca	1.2
4	Santiago	1.9

Id	Santiago	Rancagua	Talca	Renta
1	1	0	0	2.5
2	0	1	0	1.3
3	0	0	1	1.2
4	1	0	0	1.9

Automated Feature Engineering

ROC Comparison of Automated vs Manual Feature Engineering




Figura: FeatureTools ¹