

# Machine Learning

## MDS-211 Magister en Data Science

Sergio Hernández  
shernandez@ucm.cl



Universidad Católica del Maule

- ▶ Dado un conjunto de datos de entrada  $x \in X$  con  $(X_1, \dots, X_p)$  predictores y una respuesta  $y$ .
- ▶ Suponemos la existencia de una función  $f : X \mapsto Y$  tal que para cada  $y$ :

$$y = f(x) + \mathcal{E}$$

- ▶ El objetivo del aprendizaje estadístico es estimar  $f$ :

- ▶ **Predicción** : Se requiere posible obtener una estimación  $\hat{Y}$  a partir de un modelo  $\hat{f}$ .
- ▶ **Inferencia** : Se requiere interpretar la relación entre  $X$  y  $Y$ , por lo tanto el modelo  $\hat{f}$  necesita explicar  $Y$  a partir de los datos de entrada  $X$ .

## Modelo de predicción del salario.




Figura: Año




Figura: Nivel  
educacional




Figura: Edad

- ▶ En el caso de problemas de regresión simple, es posible ajustar parámetros  $w = [w_0, w_1, \dots, w_p]$  mediante el criterio de *máxima verosimilitud* para sistemas lineales Gaussianos:

## Verosimilitud

Es posible determinar los parámetros maximizando el negativo del logaritmo de la verosimilitud o mediante el método de mínimos cuadrados.

$$\begin{aligned}y_i &= f(x_i) + \epsilon \\&= w_0 + \sum_{j=1}^p w_j x_{ij} + \mathcal{N}(0, \sigma^2)\end{aligned}$$

$$\begin{aligned}p(y_i|x_i) &= \mathcal{N}(w^T x_i, \sigma^2) \\&= \frac{1}{\sigma\sqrt{2\pi}} e^{-(y_i - w^T x_i)^2 / 2\sigma^2}\end{aligned}$$

$$\mathbb{E}[Y - \hat{Y}]^2 = \underbrace{\|Y - Xw^T\|^2}_{\text{Reducible}} - \frac{n}{2} \underbrace{\log 2\pi\sigma^2}_{\text{Irreducible}}$$

- ▶ De manera de estimar  $\theta = (w, \sigma)$ , es necesario minimizar la función de error:

$$E(\theta) = \sum_{i=1}^n \left[ \frac{y_i - w_0 - \sum_{j=1}^p w_j x_{ij}}{\sigma} \right]^2 \quad (1)$$

- ▶ De manera de estimar  $\theta = (w, \sigma)$ , es necesario minimizar la función de error:

$$E(\theta) = \sum_{i=1}^n \left[ \frac{y_i - w_0 - \sum_{j=1}^p w_j x_{ij}}{\sigma} \right]^2 \quad (1)$$

- ▶ El mínimo de  $E$  ocurre cuando:

$$\frac{\partial E}{\partial \theta} = 0 \quad (2)$$

- ▶ De manera de estimar  $\theta = (w, \sigma)$ , es necesario minimizar la función de error:

$$E(\theta) = \sum_{i=1}^n \left[ \frac{y_i - w_0 - \sum_{j=1}^p w_j x_{ij}}{\sigma} \right]^2 \quad (1)$$

- ▶ El mínimo de  $E$  ocurre cuando:

$$\frac{\partial E}{\partial \theta} = 0 \quad (2)$$

- ▶ En general  $n \gg p$  por lo tanto el gradiente  $\frac{\partial E}{\partial \theta}$  induce un sistema de ecuaciones bien definido y una matriz definida positiva (y por lo tanto invertible).

## Ajuste

$$\begin{aligned} 0 &= \frac{\partial E}{\partial w_0} = -2 \sum_{i=1}^n \left[ \frac{y_i - w_0 - \sum_{j=1}^p w_j x_{ij}}{\sigma^2} \right] \\ &\quad \dots \\ 0 &= \frac{\partial E}{\partial w_p} = -2 \sum_{i=1}^n \left[ \frac{x_i \left( y_i - w_0 - \sum_{j=1}^p w_j x_{ij} \right)}{\sigma^2} \right] \end{aligned}$$

## OLS

$$0 = \sum_{i=1}^n \frac{y_i x_i^T}{\sigma^2} + w^T \left( \sum_{i=1}^n \frac{x_i x_i^T}{\sigma^2} \right)$$

$$\hat{w} = (X^T X)^{-1} X^T y$$

## Ajuste

$$\begin{aligned} 0 &= \frac{\partial E}{\partial w_0} = -2 \sum_{i=1}^n \left[ \frac{y_i - w_0 - \sum_{j=1}^p w_j x_{ij}}{\sigma^2} \right] \\ &\quad \dots \\ 0 &= \frac{\partial E}{\partial w_p} = -2 \sum_{i=1}^n \left[ \frac{x_i \left( y_i - w_0 - \sum_{j=1}^p w_j x_{ij} \right)}{\sigma^2} \right] \end{aligned}$$

## OLS

$$0 = \sum_{i=1}^n \frac{y_i x_i^T}{\sigma^2} + w^T \left( \sum_{i=1}^n \frac{x_i x_i^T}{\sigma^2} \right)$$

$$\hat{w} = (X^T X)^{-1} X^T y$$

Asumiendo una varianza constante sobre todos los puntos, el estimador de máxima verosimilitud es:

$$\sigma = \frac{\sum_{i=1}^n \left[ y_i - w_0 - \sum_{j=1}^p \hat{w}_j x_{ij} \right]^2}{n - p}$$

- ▶ Queremos determinar si existe alguna relación entre un grupo de variables independientes  $X$  y una variable dependiente  $Y$ , tal que podemos escribir  $\hat{y} = w_0 + w_1x_1 + \cdots w_px_p$ . La hipótesis nula es :

$$H_0 : w_0 = w_1 = \cdots = w_p = 0$$

- ▶ Queremos determinar si existe alguna relación entre un grupo de variables independientes  $X$  y una variable dependiente  $Y$ , tal que podemos escribir  $\hat{y} = w_0 + w_1x_1 + \cdots w_px_p$ . La hipótesis nula es :

$$H_0 : w_0 = w_1 = \cdots = w_p = 0$$

- ▶ La hipótesis alternativa es:

$$H_1 : \text{al menos existe un coeficiente } w_j > 0$$

- ▶ Queremos determinar si existe alguna relación entre un grupo de variables independientes  $X$  y una variable dependiente  $Y$ , tal que podemos escribir  $\hat{y} = w_0 + w_1x_1 + \cdots w_px_p$ . La hipótesis nula es :

$$H_0 : w_0 = w_1 = \cdots = w_p = 0$$

- ▶ La hipótesis alternativa es:

$$H_1 : \text{al menos existe un coeficiente } w_j > 0$$

- ▶ Del total de  $2^p$  subconjuntos de variables independientes, cuál es el que mejor sirve para predecir/explicar la variable de respuesta?

- ▶ Dado que necesitamos un modelo para predecir o explicar una variable de salida, necesitamos verificar la capacidad de cada variable independiente para llevar a cabo esta tarea.

- ▶ Dado que necesitamos un modelo para predecir o explicar una variable de salida, necesitamos verificar la capacidad de cada variable independiente para llevar a cabo esta tarea.
- ▶ Por otra parte, puede que cada variable por si sola no sea capaz de explicar la variable de salida, por lo que debemos considerar un subconjunto de menor dimensionalidad que  $X$ .

- ▶ Dado que necesitamos un modelo para predecir o explicar una variable de salida, necesitamos verificar la capacidad de cada variable independiente para llevar a cabo esta tarea.
- ▶ Por otra parte, puede que cada variable por si sola no sea capaz de explicar la variable de salida, por lo que debemos considerar un subconjunto de menor dimensionalidad que  $X$ .
- ▶ Las estrategias son:
  - ▶ **Selección hacia adelante** : Se comienza con la hipótesis nula (intercepto) y se agregan variables que contribuyan a disminuir el error residual.
  - ▶ **Selección hacia atrás** : Se comienza con todas las variables y se elimina aquella con el mínimo valor  $p$ , o que tenga mínima significancia estadística. Se continúa este proceso hasta llegar a algún criterio de parada.
  - ▶ **Estrategias mixtas** Combinación de selección hacia adelante y hacia atrás.

- ▶ Los modelos lineales se basan en combinaciones lineales  $y_i = f(x_i)$  de las entradas  $x = [x_1, x_2, \dots, x_p]$ .
- ▶ Cuando la cantidad de variables independientes  $p$  es grande, la función  $f(x)$  se sobre-ajusta a los datos y por lo tanto pierde capacidad de generalización.
- ▶ Una alternativa para controlar el sobre-ajuste es considerar regularización usando la norma  $\ell_2$ :

$$E(\theta) = \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \sum_{j=1}^p w_j^2$$

- ▶ A medida que crece el valor del parámetro  $\lambda \mapsto \infty$ , los coeficientes  $w_j \mapsto 0$  tienden a cero.

## Aplicable a sistemas sobredeterminados y subdeterminados.

La **función de pérdida** de la regresión Ridge se define como

$$E(\theta) = \underbrace{\|Y - X\mathbf{w}^T\|^2}_{\text{Error de ajuste}} - \underbrace{\lambda \mathbf{w}^2}_{\text{Regularización}}$$

donde  $\lambda > 0$  es el **parámetro de regularización**.

**Solución en forma cerrada** (mediante  $\nabla_{\theta} E = 0$ ):

$$2X^T(X\mathbf{w}^T - \mathbf{y}) + 2\lambda\mathbf{w} = \hat{\mathbf{w}} \quad \Rightarrow \quad \boxed{\hat{\mathbf{w}}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}}$$

# Cambio en los Valores Propios

La regresión Ridge **mejora** los valores propios de  $X^T X$ .

## Descomposición espectral de $X^T X$

$$X^T X = U D V^T \succeq 0,$$

donde  $U$  = matriz de vectores propios,  $D$  = matriz diagonal de valores propios con entradas *no negativas*  $d_1 > d_2 > \dots > d_p > 0$ .

Por tanto,  $D + \lambda I$  es siempre positiva para cualquier  $\lambda > 0$ :

$$X^T X + \lambda I = U(D + \lambda I)V^T \succ 0 \quad \forall \lambda > 0.$$

## Conclusión clave

Añadir  $\lambda I$  hace que la matriz sea **invertible**, estabilizando la solución incluso cuando  $X^T X$  es singular o está mal condicionada.

## Parámetro de Regularización $\lambda$

$$\mathbf{w}_{ridge} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}$$

$$\lambda \rightarrow 0$$

$$\mathbf{w} \rightarrow (X^T X)^{-1} X^T \mathbf{y}$$

Se reduce a mínimos cuadrados ordinarios.

$$\|Y - X\mathbf{w}^T\|^2 - \lambda \|\mathbf{w}\|^2$$

$$\lambda \rightarrow \infty$$

$$\mathbf{w} \rightarrow 0$$

Sobre-regularizado; la solución colapsa.

$$\|Y - X\mathbf{w}^T\|^2 - \lambda \|\mathbf{w}\|^2$$

- ▶ La regularización bajo la norma  $\ell_2$  controla el crecimiento de los coeficientes, haciéndolos cercanos a cero.

- ▶ La regularización bajo la norma  $\ell_2$  controla el crecimiento de los coeficientes, haciéndolos cercanos a cero.
- ▶ Una alternativa para hacer algunos de los coeficientes cero  $w_j = 0$  es considerar regularización usando la norma  $\ell_1$ :

$$E = \underbrace{\sum_{i=1}^n (y_i - f(x_i))^2}_{\text{Error de ajuste}} + \underbrace{\lambda \sum_{j=1}^p |w_j|}_{\text{Regularización}}$$

- ▶ La regularización bajo la norma  $\ell_2$  controla el crecimiento de los coeficientes, haciéndolos cercanos a cero.
- ▶ Una alternativa para hacer algunos de los coeficientes cero  $w_j = 0$  es considerar regularización usando la norma  $\ell_1$ :

$$E = \underbrace{\sum_{i=1}^n (y_i - f(x_i))^2}_{\text{Error de ajuste}} + \underbrace{\lambda \sum_{j=1}^p |w_j|}_{\text{Regularización}}$$

- ▶ A medida que crece el valor del parámetro  $\lambda \mapsto \infty$ , los coeficientes  $w_j = 0$  toman el valor cero.

## Conclusión clave

$\|\mathbf{w}\|_1 = \sum_{j=1}^p |w_j|$  es la aproximación convexa más cercana a  $\|\mathbf{w}\|_0$  (número de coeficientes distintos de cero)

## Regresión Ridge

- (+) Solución analítica en forma cerrada.
- (+) Garantías teóricas bien establecidas.
- (+) Algoritmo simple: una sola ecuación matricial.
- (−) Interpretabilidad limitada (solución densa).
- (−) No aprovecha la estructura de dispersión.

## LASSO

- (+) Éxito comprobado en imágenes, voz, etc.
- (+) Idóneo para aprendizaje profundo ( $\theta$  enorme).
- (+) Garantías teóricas en crecimiento.
- (+) Algoritmos iterativos eficientes disponibles.
- (−) Sin solución en forma cerrada.
- (−) Requiere métodos iterativos.