

Machine Learning

MDS-211 Magister en Data Science

Sergio Hernández
shernandez@ucm.cl



Universidad Católica del Maule

El error de predicción esperado de un modelo $\hat{f}(x)$ se descompone en tres términos¹:

$$\underbrace{\text{EPE}(\hat{f}(x))}_{\text{error esperado}} = \underbrace{\text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)]}_{\text{error reducible}} + \underbrace{\sigma^2}_{\text{error irreducible}}$$

- **Sesgo** (*bias*): diferencia entre la predicción esperada y el valor real. Surge de suposiciones demasiado simples $\Rightarrow$ *sub-ajuste*.

¹Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

El error de predicción esperado de un modelo $\hat{f}(x)$ se descompone en tres términos¹:

$$\underbrace{\text{EPE}(\hat{f}(x))}_{\text{error esperado}} = \underbrace{\text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)]}_{\text{error reducible}} + \underbrace{\sigma^2}_{\text{error irreducible}}$$

- ▶ **Sesgo** (*bias*): diferencia entre la predicción esperada y el valor real. Surge de suposiciones demasiado simples $\Rightarrow$ *sub-ajuste*.
- ▶ **Varianza**: cuánto cambia el modelo al entrenarlo sobre un conjunto de datos distinto. Modelos muy flexibles $\Rightarrow$ *sobre-ajuste*.

¹Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.


El error de predicción esperado de un modelo $\hat{f}(x)$ se descompone en tres términos¹:

$$\underbrace{\text{EPE}(\hat{f}(x))}_{\text{error esperado}} = \underbrace{\text{Sesgo}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)]}_{\text{error reducible}} + \underbrace{\sigma^2}_{\text{error irreducible}}$$

- ▶ **Sesgo** (*bias*): diferencia entre la predicción esperada y el valor real. Surge de suposiciones demasiado simples $\Rightarrow$ *sub-ajuste*.
- ▶ **Varianza**: cuánto cambia el modelo al entrenarlo sobre un conjunto de datos distinto. Modelos muy flexibles $\Rightarrow$ *sobre-ajuste*.
- ▶ **Ruido** (σ^2): error inherente a los datos; no puede reducirse con ningún modelo.

¹Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

El compromiso Sesgo–Varianza



- ▶ A la izquierda domina el **sesgo** (sub-ajuste); a la derecha domina la **varianza** (sobre-ajuste).
- ▶ Los ensambles buscan *romper* este compromiso: reducir la varianza (*bagging*) o el sesgo (*boosting*) sin pagar el costo del otro término.


Definición

Un *ensamble* combina las predicciones de muchos modelos diversos en un único predictor, generalmente más exacto y robusto que cualquiera de sus miembros.

Definición

Un *ensamble* combina las predicciones de muchos modelos diversos en un único predictor, generalmente más exacto y robusto que cualquiera de sus miembros.

- ▶ En lugar de ajustar un único modelo, se entrena una *colección* de modelos y se agregan sus predicciones (promedio o votación).
- ▶ **Sabiduría de las multitudes:** si cada modelo acierta mejor que el azar y sus errores son *independientes*, el voto mayoritario reduce el error a medida que crece el ensamble.



- ▶ **Bagging** (paralelo): entrena modelos sobre muestras *bootstrap* y promedia. Reduce la *varianza*.
Ejemplo: Random Forests.
- ▶ **Boosting** (secuencial): cada modelo corrige los errores del anterior. Reduce el *sesgo*.
Ejemplo: AdaBoost, Gradient Boosting, XGBoost.
- ▶ **Stacking** (apilamiento): un meta-modelo aprende a combinar las predicciones de modelos heterogéneos.

Idea

El *bootstrap* mejora la exactitud y la robustez de un estimador re-muestreando **con reemplazo** el conjunto de entrenamiento $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$.

- ▶ Cada muestra bootstrap D_b tiene tamaño n y contiene repeticiones; en promedio deja fuera $\approx 37\%$ de las observaciones ($(1 - 1/n)^n \rightarrow e^{-1}$).

Idea

El *bootstrap* mejora la exactitud y la robustez de un estimador re-muestreando **con reemplazo** el conjunto de entrenamiento $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$.

- ▶ Cada muestra bootstrap D_b tiene tamaño n y contiene repeticiones; en promedio deja fuera $\approx 37\%$ de las observaciones ($(1 - 1/n)^n \rightarrow e^{-1}$).
- ▶ Esos datos *out-of-bag* servirán más adelante para estimar el error sin un conjunto de validación aparte.

Bagging (Bootstrap Aggregation)

- ▶ *Bagging* promedia las predicciones sobre una colección de muestras bootstrap.
- ▶ Para cada muestra D_b con $b = 1, \dots, B$ se ajusta un modelo y se obtiene una predicción $f_b(x)$, de modo que el estimador final es:

$$f_{bag}(x) = \frac{1}{B} \sum_{b=1}^B f_b(x) \quad (\text{regresión}) \quad (1)$$

- ▶ En clasificación se reemplaza el promedio por el **voto mayoritario** de los B modelos.

- 1: **Entrada:** datos D , número de modelos B .
 - 2: **for** $b = 1, \dots, B$ **do**
 - 3: Generar una muestra bootstrap D_b de tamaño n desde D (con reemplazo).
 - 4: Ajustar el modelo base f_b sobre D_b .
 - 5: **end for**
 - 6: **Devolver** $f_{bag}(x) = \frac{1}{B} \sum_{b=1}^B f_b(x)$ o el voto mayoritario.
- Los B modelos son *independientes*: el entrenamiento es trivialmente paralelizable.

Por qué funciona: reducción de varianza

- ▶ Sea $h(x)$ la función que origina los datos. Cada predicción individual puede escribirse como:

$$f_b(x) = h(x) + \epsilon_b(x) \quad (2)$$

Por qué funciona: reducción de varianza

- ▶ Sea $h(x)$ la función que origina los datos. Cada predicción individual puede escribirse como:

$$f_b(x) = h(x) + \epsilon_b(x) \quad (2)$$

- ▶ El error cuadrático *promedio* de los modelos individuales es:

$$E_{AV} = \frac{1}{B} \sum_{b=1}^B \mathbb{E}[\epsilon_b(x)^2] \quad (3)$$

Por qué funciona: reducción de varianza

- ▶ Sea $h(x)$ la función que origina los datos. Cada predicción individual puede escribirse como:

$$f_b(x) = h(x) + \epsilon_b(x) \quad (2)$$

- ▶ El error cuadrático *promedio* de los modelos individuales es:

$$E_{AV} = \frac{1}{B} \sum_{b=1}^B \mathbb{E}[\epsilon_b(x)^2] \quad (3)$$

- ▶ **Suponiendo** errores de media cero $\mathbb{E}[\epsilon_b] = 0$ y *no correlacionados* $\mathbb{E}[\epsilon_b \epsilon_{b'}] = 0$ ($b \neq b'$), el error del comité es:

$$E_{COM} = \mathbb{E}\left[\left\{\frac{1}{B} \sum_{b=1}^B \epsilon_b(x)\right\}^2\right] = \frac{1}{B} E_{AV} \quad (4)$$

Por qué funciona: reducción de varianza

- ▶ Sea $h(x)$ la función que origina los datos. Cada predicción individual puede escribirse como:

$$f_b(x) = h(x) + \epsilon_b(x) \quad (2)$$

- ▶ El error cuadrático *promedio* de los modelos individuales es:

$$E_{AV} = \frac{1}{B} \sum_{b=1}^B \mathbb{E}[\epsilon_b(x)^2] \quad (3)$$

- ▶ **Suponiendo** errores de media cero $\mathbb{E}[\epsilon_b] = 0$ y *no correlacionados* $\mathbb{E}[\epsilon_b \epsilon_{b'}] = 0$ ($b \neq b'$), el error del comité es:

$$E_{COM} = \mathbb{E}\left[\left\{\frac{1}{B} \sum_{b=1}^B \epsilon_b(x)\right\}^2\right] = \frac{1}{B} E_{AV} \quad (4)$$

En el caso ideal, promediar B modelos divide el error por B . En la práctica los errores están correlacionados y la mejora es menor.

- ▶ Bagging reduce la varianza cuando se usan modelos **inestables** (árboles profundos, redes), y por lo tanto mejora la predicción.

- ▶ Bagging reduce la varianza cuando se usan modelos **inestables** (árboles profundos, redes), y por lo tanto mejora la predicción.
- ▶ Como cada $(x_j, y_j)^*$ es una muestra independiente de una distribución base $\mathcal{D}$, puede demostrarse que el re-muestreo *siempre* mejora un modelo inestable.

- ▶ Bagging reduce la varianza cuando se usan modelos **inestables** (árboles profundos, redes), y por lo tanto mejora la predicción.
- ▶ Como cada $(x_j, y_j)^*$ es una muestra independiente de una distribución base $\mathcal{D}$, puede demostrarse que el re-muestreo *siempre* mejora un modelo inestable.
- ▶ Sin embargo, sobre modelos **estables** (regresión lineal, k -NN con k grande) la ganancia es marginal: poco que des-correlacionar.

- ▶ Bagging reduce la varianza cuando se usan modelos **inestables** (árboles profundos, redes), y por lo tanto mejora la predicción.
- ▶ Como cada $(x_j, y_j)^*$ es una muestra independiente de una distribución base $\mathcal{D}$, puede demostrarse que el re-muestreo *siempre* mejora un modelo inestable.
- ▶ Sin embargo, sobre modelos **estables** (regresión lineal, k -NN con k grande) la ganancia es marginal: poco que des-correlacionar.
- ▶ Limitación: en clasificación, bagging no puede convertir un modelo malo (peor que el azar) en uno bueno.

- ▶ Los árboles de decisión son **inestables**: pequeños cambios en los datos producen árboles muy distintos (alta varianza).
- ▶ La inestabilidad se propaga: un error al particionar un nodo superior afecta a todos los nodos inferiores.
- ▶ Bagging sobre árboles ayuda, pero todos los árboles tienden a usar las mismas variables fuertes, por lo que quedan *correlacionados* y la varianza no baja lo suficiente.

Idea clave

Añadir aleatoriedad: en cada partición, considerar sólo un subconjunto aleatorio de m variables de las p disponibles.

- ▶ Esto *des-correlaciona* los árboles y reduce la varianza del ensamble más que bagging puro.

Idea clave

Añadir aleatoriedad: en cada partición, considerar sólo un subconjunto aleatorio de m variables de las p disponibles.

- ▶ Esto *des-correlaciona* los árboles y reduce la varianza del ensamble más que bagging puro.
- ▶ Valores típicos: $m \approx \sqrt{p}$ (clasificación) y $m \approx p/3$ (regresión).

Idea clave

Añadir aleatoriedad: en cada partición, considerar sólo un subconjunto aleatorio de m variables de las p disponibles.


- ▶ Esto *des-correlaciona* los árboles y reduce la varianza del ensamble más que bagging puro.
- ▶ Valores típicos: $m \approx \sqrt{p}$ (clasificación) y $m \approx p/3$ (regresión).
- ▶ Se construyen entre 100 y 500 árboles; la predicción final es el promedio (regresión) o el voto mayoritario (clasificación).

- 1: **for** $b = 1, \dots, B$ **do**
- 2: Tomar una muestra bootstrap D_b desde D .
- 3: Hacer crecer un árbol T_b sobre D_b , repitiendo en cada nodo:
- 4: (a) seleccionar m variables al azar de las p disponibles;
- 5: (b) elegir la mejor partición sólo entre esas m variables;
- 6: (c) dividir el nodo en dos hijos.
- 7: **end for**
- 8: **Devolver** el ensamble $\{T_b\}_{b=1}^B$.

- ▶ **Error out-of-bag (OOB)**: cada observación se evalúa con los árboles que no la usaron; da una estimación del error de generalización *sin* validación cruzada.


- ▶ **Error out-of-bag (OOB)**: cada observación se evalúa con los árboles que no la usaron; da una estimación del error de generalización *sin* validación cruzada.
- ▶ **Importancia de variables**: se mide cuánto cae la exactitud (o la impureza) al permutar cada variable, lo que aporta interpretabilidad.

- ▶ **Error out-of-bag (OOB)**: cada observación se evalúa con los árboles que no la usaron; da una estimación del error de generalización *sin* validación cruzada.
- ▶ **Importancia de variables**: se mide cuánto cae la exactitud (o la impureza) al permutar cada variable, lo que aporta interpretabilidad.
- ▶ Robusto a *outliers* y a variables irrelevantes; pocos hiperparámetros que ajustar.



- ▶ Bagging entrena modelos *en paralelo* y los promedia.
- ▶ Boosting ajusta una secuencia de funciones **débiles** f_m de forma *secuencial*: cada nueva función aprende de los errores de las anteriores.
- ▶ El modelo final es un *modelo aditivo*:

$$F(x) = \sum_{m=1}^M \gamma_m f_m(x) \quad (5)$$




La intuición: subir el peso de las observaciones mal clasificadas para que el siguiente modelo se concentre en ellas.

- 1: Inicializar pesos $w_i = 1/n$.
- 2: **for** $m = 1, \dots, M$ **do**
- 3: Ajustar f_m sobre los datos ponderados por w_i .
- 4: Error ponderado: $\text{err}_m = \frac{\sum_i w_i \mathbb{I}(y_i \neq f_m(x_i))}{\sum_i w_i}$.
- 5: Peso del modelo: $\alpha_m = \log((1 - \text{err}_m)/\text{err}_m)$.
- 6: Actualizar $w_i \leftarrow w_i \exp(\alpha_m \mathbb{I}(y_i \neq f_m(x_i)))$.
- 7: **end for**
- 8: **Devolver** $F(x) = \text{sign}(\sum_{m=1}^M \alpha_m f_m(x))$.



- ▶ Generaliza la idea anterior: en vez de re-ponderar, cada modelo f_m se ajusta a los **residuos** (gradiente negativo de la pérdida) del modelo acumulado.
- ▶ Permite cualquier función de pérdida diferenciable (regresión, clasificación, ranking).
- ▶ La *tasa de aprendizaje* (*learning rate*) controla cuánto contribuye cada árbol; valores pequeños requieren más árboles pero generalizan mejor.
- ▶ Implementaciones modernas: XGBoost, LightGBM, CatBoost.

Gradient Boosting ²



²<https://github.com/ageron/handson-ml2/>

Gradient Boosting: efecto de la tasa de aprendizaje



	Bagging	Boosting
Entrenamiento	Paralelo	Secuencial
Objetivo	Reducir varianza	Reducir sesgo
Modelos base	Fuertes (profundos)	Débiles (poco profundos)
Ponderación	Uniforme	Según desempeño
Riesgo	Robusto	Puede sobre-ajustar

- ▶ **Bagging / Random Forests:** rápido, robusto, buen punto de partida.
- ▶ **Boosting:** suele dar la mayor exactitud, a costa de más ajuste de hiperparámetros.

- ▶ Hastie, Tibshirani & Friedman, *The Elements of Statistical Learning*
<https://hastie.su.domains/ElemStatLearn/>
- ▶ Bishop, *Pattern Recognition and Machine Learning* (cap. 14, modelos combinados).
- ▶ Documentación de scikit-learn: *Ensemble methods*
<https://scikit-learn.org/stable/modules/ensemble.html>
- ▶ Géron, *Hands-On Machine Learning* (cap. 7)
<https://github.com/ageron/handson-ml2/>