

Tarea Práctica: Predicción de Tiempos de Sentencia en el Poder Judicial Chileno

Sergio Hernández
MDS211 - Machine Learning
Universidad Católica del Maule

1 Objetivo de la Tarea

El objetivo de esta evaluación es desarrollar, optimizar y comparar dos enfoques de Machine Learning (Redes Neuronales y Gradient Boosting) para predecir la duración de los procesos judiciales (tiempos de sentencia) utilizando datos reales del Poder Judicial de Chile. Además de la predicción puntual, se requiere una **evaluación rigurosa de la incertidumbre** asociada a dichas predicciones.

2 Descripción del Problema y Datos

Se utilizarán las estadísticas oficiales del Poder Judicial ¹. Los estudiantes deberán recolectar (o descargar) un subconjunto representativo de causas terminadas, utilizando atributos como tipo de tribunal, competencia, materia, región, entre otros.

La variable objetivo (y) será el **tiempo de sentencia** (por ejemplo, calculado como la diferencia en días entre la fecha de ingreso y la fecha de término o sentencia).

3 Requerimientos y Etapas del Proyecto

3.1 1. Recopilación y Preprocesamiento de Datos

- **Limpieza:** Tratamiento de valores nulos, registros duplicados y *outliers* en los tiempos de sentencia (ej. causas anómalamente largas o con errores de digitación).
- **Ingeniería de Características:** Codificación de variables categóricas (ej. *One-Hot Encoding* o *Feature Hashing* para competencias y materias), transformación de variables temporales y escalado/normalización para el entrenamiento de la Red Neuronal.
- **Partición:** Separación de datos en conjuntos de Entrenamiento, Validación y Prueba (se sugiere considerar una partición temporal si aplica).

3.2 2. Modelado y Ajuste de Hiperparámetros

Deberá entrenar y optimizar los siguientes modelos:

- **Modelo 1: Gradient Boosting.** Puede utilizar implementaciones como XGBoost, LightGBM o CatBoost. Realice una búsqueda de hiperparámetros (ej. tasa de aprendizaje, profundidad del árbol, número de estimadores) utilizando validación cruzada.

¹<https://numeros.pjud.cl/Estadisticas/Sentencias>

- **Modelo 2: Red Neuronal (Deep Learning).** Diseñe un perceptrón multicapa (MLP) utilizando frameworks como JAX/Flax o PyTorch. Ajuste hiperparámetros como el número de capas, neuronas, funciones de activación, *learning rate* y *batch size*.

3.3 3. Evaluación de la Incertidumbre

Dado que el tiempo de resolución de una causa judicial es altamente estocástico, la predicción puntual es insuficiente.

- Para **Gradient Boosting**: Implemente regresión por cuantiles (*Quantile Regression*) para obtener intervalos de predicción (ej. cuantiles 10 % y 90 %).
- Para la **Red Neuronal**: Implemente una red MLP para estimar los parámetros de una distribución (ej. *Gaussian Log-Likelihood* loss) o utilice librerías de inferencia probabilística como NumPyro².

3.4 4. Análisis y Conclusiones

- Compare las métricas de error puntual (RMSE, MAE).
- Compare la calidad de los intervalos de incertidumbre (ej. Cobertura empírica vs. Cobertura nominal, Amplitud promedio del intervalo).
- Discuta qué modelo ofrece una mejor calibración y cuál recomendaría para su implementación en un sistema de apoyo a la gestión de tribunales.

²https://num.pyro.ai/en/stable/getting_started.html

4 Rúbrica de Evaluación

La tarea será evaluada con base en la siguiente rúbrica (Puntaje Total: 100 puntos):

Criterio	Insuficiente (0-5 pts)	Adecuado (6-12 pts)	Excelente (13-20 pts)
1. Preprocesamiento	Manejo deficiente de nulos, sin transformación de variables ni tratamiento de outliers.	Limpieza básica, codificación estándar, pero escalado o ingeniería de características incompleta.	Preprocesamiento exhaustivo, justificación de exclusión de outliers y excelente ingeniería de características.
2. Implementación de Modelos	Modelos mal configurados, <i>data leakage</i> o errores graves en la compilación de la Red Neuronal.	Ambos modelos corren correctamente, pero la arquitectura de la red es muy simple o el GB no utiliza validación cruzada.	Implementación robusta (idealmente JAX/Flax para NN), uso de buenas prácticas y código optimizado.
3. Ajuste de Hiperparámetros	Se utilizan hiperparámetros por defecto sin ninguna estrategia de búsqueda.	Búsqueda empírica básica (<i>Grid Search</i> pequeño) sin métricas claras de validación.	Búsqueda sistemática (ej. <i>Random Search</i> o <i>Grid Search</i>) evaluada con validación cruzada.
4. Evaluación de Incertidumbre	No se evalúa la incertidumbre, solo se reportan predicciones puntuales.	Implementación teórica básica de cuantiles o MC Dropout, pero intervalos mal interpretados o no calculados correctamente.	Excelente formulación bayesiana o cuantílica. Cobertura de intervalos calculada y visualizada de forma precisa.
5. Análisis y Conclusiones	Conclusiones superficiales, no se comparan adecuadamente los intervalos ni las métricas de error.	Comparación basada solo en MAE/RMSE. Breve mención a la incertidumbre sin profundidad analítica.	Análisis crítico profundo. Discusión clara sobre el equilibrio entre precisión puntual, calidad de la incertidumbre y costo computacional.

Formato de Entrega: Se debe entregar un documento en PDF con el informe metodológico y un repositorio (o archivo .ipynb) con el código documentado.